

Documentation du Modèle NoSQL (Stripe Project)

Ce document présente le modèle NoSQL conçu pour compléter les systèmes OLTP et OLAP de l'architecture Stripe. Il stocke et analyse des données semi-structurées issues de l'activité utilisateur, de la détection de fraude et des modèles Machine Learning.

Objectif du modèle NoSQL

Le modèle NoSQL vise à stocker les données dynamiques et non structurées que le schéma relationnel ne peut gérer efficacement : logs, clics, sessions, signaux comportementaux et scores de fraude. Ces données permettent d'enrichir les analyses et d'alimenter les modèles de Machine Learning en temps réel.

MongoDB a été choisi pour sa flexibilité (schéma JSON évolutif), sa scalabilité horizontale et son intégration native avec les outils de streaming (Kafka, Debezium) et d'orchestration (Airflow).

Schéma global du modèle NoSQL

Le schéma ci-dessous illustre les principales collections NoSQL et leurs liens avec le Data Warehouse (DW). Elles partagent les clés clients et marchands avec les dimensions OLAP afin d'assurer la cohérence globale.

Collections principales : fraud_features, clickstream_events, sessions, model_scores.

Description des collections

fraud_features

Stocke les features agrégées pour chaque client ou fenêtre temporelle, utilisées par les modèles de détection de fraude.

Champ	Type	Description
id	BIGINT	Identifiant unique du document
entity_customer	JSON	Informations sur le client ou le groupe de clients
window	LINESTRING	Fenêtre temporelle d'observation (ex: 24h glissantes)

metrics	JSON	Agrégats calculés : nombre d'échecs, montants suspects, ratios de succès
updated_at	DATETIME	Dernière mise à jour des features

clickstream_events

Capture les événements utilisateur liés aux paiements, à la navigation ou à l'authentification.

Champ	Type	Description
id	BIGINT	Identifiant de l'événement
ts	DATETIME	Horodatage de l'événement
merchant_id	INT	Identifiant du marchand
customer_id	INT	Identifiant du client
session_id	LINESTRING	Identifiant de session
event	LINESTRING	Type d'événement (checkout, 3DS, refund, etc.)
status	LINESTRING	Résultat de l'événement (success, failed, pending)
geo	JSON	Données géographiques (pays, IP, région)
device	JSON	Informations sur l'appareil ou navigateur utilisé
context	JSON	Métadonnées additionnelles (source, campagne, tag)

sessions

Enregistre les sessions utilisateurs sur les sites marchands intégrés à Stripe.

Champ	Type	Description
id	BIGINT	Identifiant de session
merchant_id	INT	Marchand concerné
customer_id	INT	Client concerné
started_at	DATETIME	Date/heure de début
ended_at	DATETIME	Date/heure de fin
steps[]	JSON	Liste ordonnée d'actions réalisées
device	JSON	Caractéristiques du terminal
geo	JSON	Localisation de la session
duration_sec	INT	Durée totale en secondes

model_scores

Conserve les scores produits par les modèles de détection de fraude (offline ou temps réel).

Champ	Type	Description
id	BIGINT	Identifiant du score
transaction_id	INT	Référence de la transaction concernée
timestamp	DATETIME	Date du scoring
model	JSON	Métadonnées sur le modèle utilisé (nom, version, source)
score	FLOAT	Score de fraude calculé
threshold	FLOAT	Seuil de décision du modèle

label	LINESTRING	Résultat de la décision (fraud, legit, review)
signals	LINESTRING	Principales features contributives

Intégration avec OLTP et OLAP

Les collections NoSQL sont alimentées par les flux de données en provenance des systèmes OLTP et OLAP :

- Les transactions du DW (fact_transactions) alimentent les scores de fraude.
- Les événements utilisateurs (clickstream) enrichissent les features comportementales.
- Les résultats des modèles sont stockés dans model_scores puis réinjectés dans l'OLTP via API.

Cas d'usage principaux

1. Détection de fraude en quasi temps réel.
2. Analyse comportementale (sessions, clics, taux de conversion).
3. Suivi de performance des modèles ML (drift, taux d'alerte).
4. Intégration avec le Data Warehouse pour analyses multi-sources.

Le modèle NoSQL joue un rôle clé dans la composante 'intelligence adaptative' de Stripe. Il offre une vue dynamique, non structurée, complémentaire du stockage analytique classique.