

Stratégie d'intégration Machine Learning (Stripe Project)

Contexte et objectifs

Stripe intègre le Machine Learning (ML) au cœur de son écosystème de données afin de renforcer la sécurité et l'efficacité de ses opérations. Le principal cas d'usage concerne la **détection de fraude en temps réel**, mais l'infrastructure permet également la personnalisation client et la prévision de revenus. L'objectif de cette stratégie est de décrire comment les modèles ML s'intègrent de manière fluide avec les environnements OLTP, OLAP et NoSQL.

Architecture fonctionnelle ML

Le pipeline ML repose sur une approche duale :

- Offline : entraînement périodique sur données historiques consolidées (OLAP).
- Online : scoring en temps réel sur transactions entrantes (OLTP + NoSQL).

Le schéma logique est le suivant :

1. Les transactions sont capturées dans le système OLTP.
2. Des flux de données (CDC / Kafka) alimentent MongoDB (` fraud\_features `).
3. Les features sont utilisées pour entraîner un modèle de détection de fraude (XGBoost).
4. Le modèle est versionné et suivi dans MLflow.
5. Une API FastAPI sert le modèle pour du scoring en temps réel.
6. Les résultats (score, décision) sont enregistrés dans MongoDB (` model\_scores `) et éventuellement réinjectés dans OLTP.

Sources de données

Source	Système	Utilisation ML
transactions	OLTP (PostgreSQL)	Historique de paiements et labels (fraude confirmée)
fact_transactions	OLAP (DW)	Entraînement et validation du modèle

fraud_features	MongoDB	Features comportementales temps réel
model_scores	MongoDB	Résultats du scoring en production
clickstream_events / sessions	MongoDB	Signaux front-end enrichissant les modèles

Pipeline d'intégration (Offline + Online)

- Phase Offline (Batch) :
 - Extraction des transactions et historiques depuis OLAP.
 - Nettoyage, feature engineering et split train/test.
 - Entraînement du modèle sous MLflow (tracking des hyperparamètres, métriques F1, AUC).
 - Sauvegarde du modèle validé dans un registre (MLflow Model Registry).
- Phase Online (Temps réel) :
 - Une API FastAPI expose le modèle sous forme de service REST.
 - Chaque transaction est enrichie par des features de MongoDB.
 - Le modèle prédit un score de risque et une classe ('legit', 'review', 'fraud').
 - Le résultat est loggé dans `model\_scores` pour suivi et audit.

Infrastructure technique

Les principaux outils et technologies utilisés sont :

Composant	Rôle
Airflow	Orchestration du pipeline d'entraînement et de déploiement
MLflow	Suivi des expériences, des modèles et des métriques
Kafka	Flux temps réel entre OLTP, NoSQL et API
FastAPI	Serveur REST pour le scoring en ligne

MongoDB	Stockage des features et résultats de scoring
PostgreSQL (DW)	Données historiques et supervision analytique
Docker / Hugging Face	Conteneurisation et hébergement du modèle

Monitoring et retraining

Le suivi de performance des modèles est essentiel pour garantir la fiabilité du système de détection de fraude. Deux niveaux de surveillance sont mis en place :

- **Monitoring temps réel** : vérification du taux de prédictions 'fraud' et détection d'anomalies (drift des features).
- **Retraining planifié** : réentraînement hebdomadaire si la dérive dépasse un seuil (5% du score moyen). Les métriques sont enregistrées dans MLflow et visualisées dans un dashboard Streamlit ou Power BI.

Gouvernance et conformité

Le modèle ML respecte les principes de conformité et d'auditabilité :

- Journalisation de chaque décision de modèle (score, seuil, features principales).
- Conservation des versions et des artefacts (modèles, données d'entraînement) dans MLflow.
- Accès restreint et chiffrement des données sensibles.
- Documentation du processus d'entraînement pour audit RGPD / PCI-DSS.

Recommandations et perspectives

La stratégie ML proposée permet une intégration fluide entre les environnements opérationnels et analytiques. Elle favorise la détection proactive de la fraude et la personnalisation client en temps réel. Les prochaines étapes incluent :

- L'ajout d'un pipeline de validation automatisé (CI/CD ML).
- L'utilisation d'Evidently AI pour la détection automatique du drift.
- L'extension des modèles vers la segmentation et la recommandation client.