

Cas d'usage consolidés (Stripe Project)

Ce document présente une série de cas d'usage illustrant la complémentarité entre les systèmes OLTP, OLAP, NoSQL et Machine Learning au sein de l'architecture de données Stripe. Ces scénarios démontrent comment les différentes couches collaborent pour générer des insights métiers, renforcer la sécurité et améliorer la prise de décision en temps réel.

Cas d'usage: Revenu et performance marchands

Ce cas d'usage illustre la capacité du Data Warehouse à agréger et analyser les performances économiques des marchands. Les données proviennent de la table de faits `fact\_transactions` et des dimensions `dim\_merchant`, `dim\_plan` et `dim\_date`. Les indicateurs clés incluent le chiffre d'affaires mensuel, le taux de remboursement et la répartition par plan d'abonnement.

Indicateurs principaux: revenu total, refund rate, nombre de transactions par plan.

Source: OLAP (PostgreSQL DW).

Cas d'usage: Détection de fraude et comportements suspects

La détection de fraude repose sur la combinaison des flux temps réel (OLTP), des signaux comportementaux (NoSQL) et du scoring des modèles ML. MongoDB (`fraud\_features`, `model\_scores`) capture les signaux et les résultats de scoring, tandis que les transactions validées ou refusées dans PostgreSQL fournissent les labels pour le réentraînement.

Indicateurs principaux: taux de fraude par pays, taux d'échec, top IP suspectes.

Source: OLTP + NoSQL + MLflow.

Cas d'usage: Segmentation clients et churn

Le modèle de churn prédictif permet d'identifier les clients à risque de désabonnement. Les données proviennent du DW (`fact\_transactions`, `dim\_customer`, `dim\_plan`) et des signaux NoSQL (`sessions`, `clickstream\_events`). Les modèles de classification sont entraînés à partir des comportements historiques (fréquence d'achat, durée d'abonnement, montant moyen, inactivité).

Indicateurs principaux: churn rate, lifetime value (LTV), taux de rétention.

Source: OLAP + ML.

Cas d'usage: Analyse comportementale et sessions utilisateurs

Les collections `sessions` et `clickstream\_events` permettent d'analyser les comportements front-end et la navigation des utilisateurs. Ces données sont essentielles pour comprendre les parcours d'achat et les points de friction (abandons de panier, échecs de paiement).

Indicateurs principaux: durée moyenne de session, taux de conversion, taux d'abandon.

Source: NoSQL (MongoDB).

Cas d'usage: Monitoring et performance des modèles ML

Ce cas d'usage vise à évaluer la performance et la dérive des modèles de détection de fraude. Les scores sont stockés dans `model\_scores`, et les métriques (F1-score, AUC, precision/recall) sont suivies via MLflow. Le retraining automatique est déclenché lorsque la dérive de distribution dépasse un seuil défini.

Indicateurs principaux: F1-score, AUC, drift des features, fréquence de retraining.

Source: MLflow + MongoDB.

Exemples de requêtes hybrides OLAP + NoSQL

Exemple 1 – Taux de fraude par pays (OLAP + NoSQL)

SQL (DW) :

```
```sql
SELECT m.country_code, COUNT(*) FILTER (WHERE f.status='failed') * 100.0 / COUNT(*) AS
fraud_rate
FROM dw.fact_transactions f
JOIN dw.dim_merchant m ON m.merchant_id = f.merchant_id
GROUP BY m.country_code;
```
```

MongoDB (fraud_features) :

```
```js
db.fraud_features.aggregate([
 { $group: { _id: "$geo.country", avg_score: { $avg: "$metrics.fraud_score" } } },
 { $sort: { avg_score: -1 } }
]);
```
```

Ces deux résultats peuvent être corrélés dans un tableau de bord Power BI ou Streamlit pour identifier les pays les plus exposés.

Exemple 2 – Durée moyenne de session vs taux de conversion (NoSQL + OLAP)

MongoDB :

```
```js
db.sessions.aggregate([
 { $group: { _id: "$merchant_id", avg_duration: { $avg: "$duration_sec" } } }
]);
```
```

SQL :

```
```sql
SELECT merchant_id, SUM(CASE WHEN status='succeeded' THEN 1 ELSE 0 END)::float /
COUNT(*) AS conversion_rate
FROM dw.fact_transactions
GROUP BY merchant_id;
```
```

Ces deux agrégations peuvent être jointes dans un outil analytique pour mesurer l'impact de la durée moyenne de session sur la conversion.

Visualisation et exploitation

Les indicateurs issus de ces cas d'usage peuvent être exploités dans un tableau de bord Power BI ou Streamlit. Le tableau de bord présentera :

- Le chiffre d'affaires global et par pays (OLAP).
- Le taux de fraude et le top des IP suspectes (NoSQL + ML).
- Les indicateurs de churn et de rétention (ML + DW).
- Les durées moyennes de session et les taux de conversion (NoSQL).
- Le suivi du drift et des performances modèles (MLflow).