



BLOC 2 – Architecture données

Stripe project

CDSD - Loic Valentini – Décembre 2025





Construire une architecture de données intégrée pour Stripe

Une donnée en plein expansion

Stripe traite des milliards de transactions dans 100+ pays

Des données multiples : paiements, abonnements, logs, détection de fraude...

Une complexité croissante : volumes, hétérogénéité, conformité

Des systèmes encore cloisonnés

OLTP, OLAP et NoSQL fonctionnent en silos

Difficulté à croiser les données transactionnelles et comportementales

Objectif de fluidifier les échanges et unifier les pipelines

Vers une architecture intégrée et temps réel


Construire un pipeline unifié (batch + streaming)

Garantir rapidité, fiabilité et analyse instantanée

Supporter fraude, analytique et pilotage client dans un même écosystème



- Batch ETL/ELT
- Temps réel
- Machine Learning
- Dashboard





Un écosystème data unifié et opérationnel

Une modélisation complète et cohérente

3 environnements : OLTP (PostgreSQL), OLAP (Snowflake / PostgreSQL DW) et NoSQL (MongoDB)
Schémas normalisés et en étoile respectant les bonnes pratiques de Data Modeling

Pipelines d'intégration fonctionnels

Airflow + dbt pour charger les batchs quotidiens vers le Data Warehouse
Kafka + Debezium pour les flux temps réel entre OLTP, NoSQL et Machine Learning

Analyses et indicateurs clés

10 requêtes OLAP : revenus, succès de paiement, churn, croissance...
5 requêtes NoSQL : détection d'anomalies, taux d'échec, IP suspectes...

Intelligence et restitution

Intégration d'un modèle Machine Learning pour la fraude
Tableaux de bord Power BI / Streamlit pour suivre les KPIs en temps réel

Cohérence et scalabilité

Synchronisation en continu

Vision analytique complète

Production et supervision IA



Vers la production : perspectives du projet

Industrialisation sur le cloud

Déploiement sur AWS ou GCP avec stockage managé (S3, BigQuery, Snowflake)

Automatisation complète des flux

Orchestration quotidienne via Airflow et dbt Cloud pour des pipelines robustes

Extension des modèles Machine Learning

Ajout de modèles pour le churn, la recommandation et la segmentation client

Surveillance continue des performances

Tracking automatique des métriques, dérives et décisions suite aux détections de fraude

Gouvernance et documentation

Mise en place d'un Data Catalog, métadonnées, et suivi des accès pour conformité

Enrichissement analytique

Intégration future de données comportementales et de logs dans le modèle OLAP

Monitoring et qualité

Supervision du pipeline et exécution de tests automatisés (CI/CD, validation des données)



Merci !

